

챕터 7 실제로 써보니. 캐시와 모니터링

이번 챕터가 끝나면

- **ResponseCache(TTL)** 로 같은 질문에 같은 답을 0.1초에 돌려줍니다
- **EmbeddingCache** 로 같은 텍스트의 임베딩 재계산을 줄입니다
- **TokenTracker** 로 LLM 호출별 토큰, 비용, 응답시간을 집계합니다
- **Retry 로직**(최대 3회, 간격 2초)으로 네트워크, 파싱 오류에서 자동 회복합니다
- 이 모든 것을 **ConnectHRAgent**라는 운영용 래퍼로 한 번에 감쌉니다

준비하기. 실습 시작 전 한 번만 설정

1. 실습 폴더 이동

터미널 폴더 이동

```
cd rag-start/ex07
```

파일 구조는 다음과 같습니다.

ex07 디렉토리

```

ex07/
├── run.py
├── src/
│   ├── agent_config.py      # [실습] ConnectHRAgent 운영 래퍼
│   ├── cache.py             # [실습] ResponseCache + EmbeddingCache
│   ├── monitoring.py         # [실습] TokenTracker + JSON 로깅
│   ├── llm_factory.py        # [참고] LLM 인스턴스 생성
│   ├── agent_helpers.py      # [참고] RAG 체인 + 라우팅 매핑
│   ├── router.py             # [참고] 3단계 QueryRouter (챕터 6)
│   └── tools/                # [참고] 도구 4개 (파일 분리)
│       ├── leave_balance.py
│       ├── sales_sum.py
│       ├── list_employees.py
│       └── search_documents.py
├── app/
│   ├── main.py               # [참고] FastAPI 진입점
│   ├── chat_api.py           # [참고] Agent API 엔드포인트
│   └── database.py            # [참고] PostgreSQL 연결
├── templates/chat.html       # [참고] 채팅 UI
└── static/                   # [참고] UI 스타일
    
```

2. 실습 환경 구축

터미널 환경 구성. macOS / Linux

```

cd ex07
cp .env.example .env
python3.12 -m venv .venv
source .venv/bin/activate
docker compose up -d
ollama pull llama3.1:8b
pip install -r requirements.txt
    
```

터미널 환경 구성. Windows

```

cd ex07
copy .env.example .env
py -3.12 -m venv .venv
.venv\Scripts\activate
docker compose up -d
ollama pull llama3.1:8b
pip install -r requirements.txt
    
```

3. 사용할 라이브러리

패키지	역할
<code>langchain</code> · <code>langchain-ollama</code>	에이전트 프레임워크·LLM 연결
<code>langchain-chroma</code> · <code>chromadb</code>	벡터 DB
<code>sentence-transformers</code>	ko-sroberta 임베딩
<code>psycopg2-binary</code>	PostgreSQL 드라이버
<code>fastapi</code> · <code>uvicorn</code>	웹 API 서버
<code>rich</code>	운영 로그 가독성 (컬러·테이블 출력)

`.env` 핵심 상수입니다. 이번 챕터에서 캐시·로깅 관련 항목이 새로 등장합니다.

상수	기본값	역할
<code>CACHE_TTL</code>	<code>3600</code>	응답 캐시 TTL (초)
<code>CACHE_MAX_SIZE</code>	<code>1000</code>	응답 캐시 최대 항목 수
<code>EMBEDDING_CACHE_DIR</code>	<code>./outputs/embedding_cache</code>	임베딩 벡터 저장 경로
<code>LOG_LEVEL</code>	<code>INFO</code>	로그 레벨
<code>USE_JSON_LOG</code>	<code>false</code>	JSON 구조화 로그 여부

4. 실습 순서

각 주제별로 이론을 읽고 바로 관련 파일 TODO를 채우는 구조입니다.

1. **7.2 캐시** — ResponseCache·EmbeddingCache 이론 → `src/cache.py` 작성
2. **7.3 모니터링** — TokenTracker 이론 → `src/monitoring.py` 작성
3. **7.4 Retry + ConnectHRAgent** — 재시도·운영 래퍼 이론 → `src/agent_config.py` 작성
4. **7.5 서버 실행** — 같은 질문 두 번 던져 캐시 적중 확인

7.1 "같은 질문에 또 20초?"




그림 7-1. 운영 안정화. 캐시와 업무 일지, 재시도까지 붙은 사서

챕터 6에서 통합 에이전트를 완성한 뒤 일주일이 흘렀습니다. 동료들 자리에 한 번씩 깔리던 웃음이 이제는 슬랙 채널에 모이고 있었습니다. 월요일 오전 9시 반. 오픈이는 커피잔을 책상에 내려놓고 슬랙을 열었습니다.

동료 : "아, 병가 증빙 필요한지 아까도 물어봤는데, 또 20초 기다려야 해요?"

20초. 커서만 깜빡이는 화면에서 20초는 깁니다. 오픈이가 터미널을 열어 같은 질문을 던져 봤습니다. 로딩 스피너가 또 20초 동안 돌아갔습니다.

같은 질문인데 왜 매번 처음부터 찾는 거지.

건너편 자리의 다른 동료가 의자를 돌리며 한마디 더 었었습니다.

동료 : "우리 팀에서 하루에 30번은 쓰는 것 같은데, 얼마나 쓰고 있는 건지 파악이 안 돼요."

얼마나 쓰는지. 호출 횟수, 응답 시간, 토큰 수. 어디에도 기록이 없었습니다. 슬랙 채널을 위로 끌어올려 보니 간간이 "에러가 났어요" 메시지도 섞여 있었습니다. 확인해 보면 네트워크 타임아웃이거나 LLM 파싱 실패. 잠시 뒤 다시 물어보면 정상인데 사용자 입장에서선 "고장났다"였습니다.

속도, 사용량, 실패. 세 가지가 한꺼번에 문제가 됐다.

옆 자리 팀장이 지나가다 모니터를 훑듯 봤습니다.

팀장 : "같은 질문에 매번 서가를 뒤지는 사서가 있으면 어떻겠어?"

오픈이 : "비효율적이죠."

팀장 : "그럼 뭐가 필요해?"

잠시 생각했습니다. 팀장은 답을 끌고 가는 스타일이 아니라 늘 질문을 던지는 쪽이었습니다.

메모장. 한 번 찾은 답을 적어 두는 메모장이 있으면 되잖아.

7.2 ResponseCache + EmbeddingCache

메모장 이야기는 팀장 자리로도 이어졌습니다. 오픈이가 화이트보드 앞에 서서 마커 뚜껑을 딸깍 열었습니다.

팀장 : "메모장에 유통기한은 어떻게 할 건데?"

오픈이 : "1시간 정도요. 규정이 자주 바뀌는 건 아니지만, 하루를 넘기면 옛날 답을 줄 수도 있으니까요."

팀장 : "그 감각이 맞아. 메모장은 오래 들고 있을수록 독이 돼."

챕터 5에서 사서에게 대화용 메모장(**WindowMemory**)을 줬던 기억이 떠올랐습니다. 이번에는 **메모장을 두 권 더** 엮었습니다. 하나는 답변을 적는 메모장, 또 하나는 임베딩을 적는 메모장입니다.

답변 메모장 (ResponseCache)

같은 질문이 또 들어오면 서가까지 다시 갈 필요가 없습니다. 이전에 적어 둔 답을 바로 읽어 주면 됩니다. 단, 메모장에는 **유통기한(TTL)** 이 있습니다. 1시간 지나면 지웁니다. 사내 규정이 바뀌었을 수도 있기 때문입니다.




그림 7-4. ResponseCache는 유통기한이 있는 메모장. 같은 질문이 TTL 안에 다시 오면 서가(LLM)를 건너뛰니다

임베딩 메모장 (EmbeddingCache)

질문을 벡터로 바꾸는 데에도 시간이 듭니다. 같은 문장을 여러 번 변환할 필요는 없습니다. 한 번 계산한 벡터를 파일로 저장해 두면 다음엔 바로 꺼내 씁니다. EmbeddingCache는 유통기한이 없습니다. 벡터 값은 텍스트만 같으면 언제나 같기 때문입니다.

EmbeddingCache

outputs/embedding_cache/

"연차 규정" → a1f3c7.pkl

"휴가 절차" → d9e2b5.pkl

"보안 정책" → 7c4a8f.pkl

새 텍스트가 들어오면

"연차 규정"

HIT

파일 존재 → pickle.load → 벡터 반환 즉시

"근태 관리"

MISS

파일 없음 → 임베딩 계산 → 새 파일 저장 약 0.5초

그림 7-5. EmbeddingCache는 텍스트별 전용 서랍. 서랍이 있으면 파일을 그대로 꺼내고, 없으면 계산 후 서랍 하나를 추가합니다

실습 1. cache.py

ex07/src/cache.py 상단에는 캐시 동작을 조절하는 상수 세 개가 이미 선언돼 있습니다. .env 값이 없으면 이 기본값을 씁니다.

설명 ex07/src/cache.py. 모듈 상수

```
DEFAULT_RESPONSE_TTL = 3600 # 응답 캐시 TTL (초). 1시간
DEFAULT_RESPONSE_CACHE_MAX_SIZE = 1000 # 최대 저장 항목 수
DEFAULT_EMBEDDING_CACHE_DIR = "./outputs/embedding_cache"
```

이제 두 클래스의 `get` · `set` TODO의 `pass` 를 지우고 아래 코드를 채워 봅시다. 키 생성(SHA-256 해시)과 파일 I/O는 `_cache_utils.py` 에 헬퍼로 이미 준비돼 있어서, 우리는 **TTL 검사**와 **최대 크기 관리**에만 집중하면 됩니다.

먼저 클래스 골격과 `__init__` 입니다. 메모장의 **용량 한도**(`max_size`), **유통기한**(`ttl`), 그리고 히트·미스 카운터를 준비합니다.

실습 1 ex07/src/cache.py. ResponseCache — 초기화

```
class ResponseCache:
    """TTL 기반 인메모리 응답 캐시."""

    def __init__(self, ttl=DEFAULT_RESPONSE_TTL, max_size=DEFAULT_RESPONSE_CACHE_MAX_SIZE):
        # 1. TTL·max_size는 .env 또는 기본값에서 주입 (3600초, 1000개)
        self.ttl = ttl
        self.max_size = max_size
        # 2. 메모장 본체: key → (value, expires_at) 튜플
        self._store = {}
        # 3. 통계 카운터 - 운영 중 적중률을 보기 위한 값
        self._hits = 0
        self._misses = 0
        logger.info("[ResponseCache] 초기화 완료 (TTL: %d초, 최대 크기: %d)", ttl, max_size)
```

`self._store` 가 **메모장 본체**입니다. 키 하나당 (실제 답변, 만료 시각) 튜플을 담습니다. 만료 시각을 같이 저장해 두는 것이 TTL 구현의 핵심입니다.

이제 조회 메서드 `get()` 입니다. **세 가지 경로**로 갈라집니다. 키 없음 → 만료됨 → 적중. 어느 쪽이든 카운터 갱신과 로깅을 잊지 않아야 합니다.

실습 1 ex07/src/cache.py. ResponseCache.get

```
def get(self, query, context=""):
    """캐시에서 응답을 조회합니다 (TTL 만료 체크)."""
    # TODO: get - TTL 검사 후 HIT/MISS 반환
    # 1. 질문(+문맥)을 SHA-256 해시로 변환해 고정 길이 키로
    key = make_response_key(query, context)

    # 2. 저장소에 키가 아예 없으면 MISS
    entry = self._store.get(key)
    if entry is None:
        self._misses += 1
        logger.debug("[ResponseCache] 미스: key=%s...", key[:12])
        return None

    # 3. 있더라도 만료 시각이 지났으면 삭제 후 MISS
    value, expires_at = entry
    if time.time() > expires_at:
        del self._store[key]
        self._misses += 1
        logger.debug("[ResponseCache] 만료: key=%s...", key[:12])
        return None

    # 4. 살아 있으면 HIT - 남은 TTL 로그로 남겨 디버깅 편하게
    self._hits += 1
    logger.info("[ResponseCache] 적중: key=%s... (잔여 TTL: %.0f초)", key[:12], expires.
    return value
```

핵심은 **2·3·4 분기가 모두 카운터를 갱신**한다는 점입니다. 만료된 항목은 그 자리에서 삭제하고 MISS로 처리합니다. 같은 질문이어도 유효기한이 지났으면 새 답을 받아 와야 하기 때문입니다.

저장할 때는 **용량 관리**가 함께 들어갑니다. 메모장 페이지가 `max_size` (기본 1000)를 넘으면 **만료 시각이 가장 이른 항목**부터 한 건 지우고 새 항목을 넣습니다.

실습 1 ex07/src/cache.py. ResponseCache.set

```
def set(self, query, value, context=""):
    """캐시에 응답을 저장합니다 (max_size 초과 시 오래된 항목 제거)."""
    # TODO: set - max_size 초과 시 가장 오래된 항목 제거
    # 1. 조회와 같은 방식으로 키 생성
    key = make_response_key(query, context)

    # 2. 용량 초과 시 만료 임박 항목 한 건 제거
    if len(self._store) > self.max_size:
        oldest_key = min(self._store, key=lambda k: self._store[k][1])
        del self._store[oldest_key]
        logger.debug("[ResponseCache] 최대 크기 초과로 항목 제거: key=%s...", oldest_key[:12])

    # 3. 만료 시각 = 지금 + TTL. 튜플로 저장
    expires_at = time.time() + self.ttl
    self._store[key] = (value, expires_at)
    logger.info("[ResponseCache] 저장: key=%s... (만료: %.0f초 후)", key[:12], self.ttl)
```

`min(self._store, key=lambda k: self._store[k][1])` 이 가장 먼저 만료될 항목을 찾는 부분입니다. 튜플의 두 번째 요소(`expires_at`)가 작을수록 만료가 가깝습니다. 용량을 딱 채우기 전에 한 건을 빼 주므로, 메모장은 항상 `max_size` 아래로 유지됩니다.

마지막으로 클래스 아래에는 **운영용 편의 메서드** 두 개가 이미 완성된 채로 들어 있습니다. 우리가 구현할 부분은 없고, 작동만 기억하면 됩니다.

설명 ex07/src/cache.py. ResponseCache.clear / stats

```
def clear(self):
    """만료된 캐시 항목을 제거합니다."""
    return response_cache_clear(self)

def stats(self):
    """캐시 통계를 반환합니다 (_hits / _misses / 현재 크기 등)."""
    return response_cache_stats(self)
```

`clear()` 는 만료된 항목을 일괄 정리하고, `stats()` 는 적중·미스 수와 현재 크기를 딕셔너리로 돌려줍니다. 실제 로직은 `_cache_utils.py` 헬퍼가 맡아 위임만 하고 있습니다. `stats()` 가 반환하는 값은 이후 상태 확인 대시보드에서 "캐시 적중률 72%" 같은 숫자로 쓰입니다.

여기까지가 **답변 메모장**입니다. 이제 두 번째 메모장인 **임베딩 메모장**으로 넘어갑니다. 같은 "캐시"라는 이름이지만 **무엇을 얼마나 어디에** 기록하느냐가 완전히 다릅니다.

	ResponseCache 답변 메모장	EmbeddingCache 임베딩 메모장
기록하는 것	LLM이 만든 완성된 답변 문자열	"연차 규정"처럼 텍스트를 숫자 벡터 로 변환한 결과
유효기한	1시간(TTL). 규정이 바뀌면 답도 바뀌어야 하니까	없음 . 텍스트가 같으면 벡터 값은 언제 계산해도 같음
저장 위치	메모리 디렉터리 (서버 재시작 시 소멸)	디스크 파일 <code>cache_dir/{sha256}.pkl</code>
메서드 구조	<code>get()</code> + <code>set()</code> 두 번 호출	<code>get_or_compute(text, compute_fn)</code> 한 번이면 끝

마지막 행이 구현 차이를 만듭니다. 답변 메모장은 `get()` 이 MISS를 반환하면 호출자가 "그럼 LLM을 돌리자"를 직접 결정해야 합니다. 임베딩 메모장은 **MISS일 때 무엇을 계산할지**(`compute_fn`)를 미리 받아 두기 때문에 호출자는 결과만 기다리면 됩니다.

`compute_fn` 이란? 캐시 미스일 때 값을 계산할 함수입니다. "연차 규정" 같은 텍스트를 받으면 768차원 벡터를 돌려주는 임베딩 함수를 여기에 넘깁니다. `EmbeddingCache` 가 미스 시 `compute_fn(text)` 로 호출해 계산하고 결과를 파일에 저장합니다.

파일 I/O의 귀찮은 부분(해시 파일명, `pickle` 직렬화, 히트·미스 카운팅)은 `_cache_utils.py` 의 `embedding_get` · `embedding_set` 이 맡습니다. 우리는 이 두 헬퍼를 어떤 순서로 호출할지만 결정합니다.

실습 1 ex07/src/cache.py. EmbeddingCache

```
class EmbeddingCache:
    """로컬 파일 기반 임베딩 캐시."""

    def __init__(self, cache_dir=DEFAULT_EMBEDDING_CACHE_DIR):
        self.cache_dir = Path(cache_dir)
        self.cache_dir.mkdir(parents=True, exist_ok=True)
        self._hits = 0
        self._misses = 0
        logger.info("[EmbeddingCache] 초기화 완료 (캐시 디렉토리: %s)", self.cache_dir)

    def get_or_compute(self, text, compute_fn):
        """캐시 히트면 반환, 미스면 compute_fn으로 계산 후 저장합니다."""
        # TODO: get_or_compute - 캐시 히트면 반환, 미스면 계산 후 저장
        emb, hits_delta, misses_delta = embedding_get(self.cache_dir, text, None)
        self._hits += hits_delta
        self._misses += misses_delta

        if emb is not None:
            return emb

        emb = compute_fn(text)
        embedding_set(self.cache_dir, text, emb)
        return emb

    def stats(self):
        """캐시 통계를 반환합니다."""
        return embedding_cache_stats(self)
```

`make_response_key`, `embedding_get`, `embedding_set` 는 `_cache_utils.py` 의 보조 함수입니다. 해시 계산, 파일 이름 규칙, `pickle` 직렬화 등 지루한 I/O는 전부 헬퍼가 맡고, 우리는 TTL 검사와 용량 관리 로직만 다루는 구조입니다.

7.3 TokenTracker — 업무 일지를 쓴다

화이트보드의 두 번째 네모가 비어 있었습니다. 동료가 던졌던 두 번째 불만이 떠올랐습니다. *얼마나 쓰고 있는 건지 파악이 안 돼요.*

오픈이 : "사용량 추적이 안 되고 있어요. 하루에 몇 건 처리하는지, 응답 시간은 평균 얼마인지 전혀 모릅니다."

팀장 : "사서한테 업무 일지를 쓰게 해."

업무 일지. 매 호출마다 한 줄씩 기록을 남기는 것입니다.

- 오늘 총 몇 건 처리했는가
- 입력, 출력 토큰을 얼마나 썼는가
- 평균 응답 시간은 얼마인가
- API 비용은 얼마가 나갔는가

실무에서는 **Langfuse**, **LangSmith** 같은 전문 모니터링 도구가 이 역할을 합니다. 호출별 토큰, 비용, 지연을 자동 수집해 대시보드로 보여 줍니다. 하지만 도구를 붙이기 전에 **무엇을 측정해야 하는지**를 먼저 이해해야 합니다. 이 책에서는 `TokenTracker` 라는 간단한 클래스를 직접 만들어 감을 잡아 봅니다.

TokenTracker 왜 직접 만드나? Langfuse를 바로 붙이면 대시보드는 예쁘게 나오지만 "무엇이 수집되는지, 왜 그 값이 필요한지"를 이해하지 못한 채 지나가기 쉽습니다. 이 책에서는 **호출 단위로 남길 필드 4개**(입력 토큰·출력 토큰·응답 시간·비용)를 직접 쌓아 보면서 모니터링의 기본기를 체감한 뒤, 실무에서 Langfuse로 교체하는 순서를 권합니다.

실습 2. monitoring.py

`ex07/src/monitoring.py` 의 `TokenTracker` 는 세 부분으로 읽어 나갑니다. **단가 표 → record() 메서드 → 헬퍼 위임 메서드**. 우리가 채울 TODO는 `record()` 한 곳이며, `pass` 를 지우고 아래 코드를 작성합니다.

먼저 **클래스 골격**입니다. 모델별 단가 표는 이미 선언돼 있고, `__init__` 에서는 기록 리스트·누적 합계 카운터·로거만 준비합니다.

실습 2 ex07/src/monitoring.py. TokenTracker — 골격

```
class TokenTracker:
    """LLM API 호출별 토큰 사용량을 추적합니다."""

    # 1. 모델별 단가 표 (달러/1000토큰, 참고용)
    COST_PER_1K_TOKENS = {
        "gpt-4o-mini": {"input": 0.00015, "output": 0.0006},
        "gpt-4o": {"input": 0.005, "output": 0.015},
        "deepseek-r1:8b": {"input": 0.0, "output": 0.0}, # 로컬 모델: 무료
        "llama3.1:8b": {"input": 0.0, "output": 0.0}, # 로컬 모델: 무료
    }

    def __init__(self):
        # 2. 개별 호출 기록 리스트
        self._records = []
        # 3. 누적 토큰 합계 - summary()가 빠르게 읽기 위해 미리 계산
        self._total_input_tokens = 0
        self._total_output_tokens = 0
        self._logger = logging.getLogger(__name__)
```

로컬 모델(deepseek-llama)은 비용이 0이라 단가 표에 0.0 으로 못 박혀 있습니다. OpenAI 모델은 공식 요금제에서 가져온 값입니다. `record()` 에서 이 표를 보고 비용을 계산합니다.

다음은 **TODO가 있는** `record()` 메서드입니다. 한 호출마다 세 가지를 처리합니다. 비용 계산 → 기록 딕셔너리 조립 → 누적 카운터 갱신.

실습 2 ex07/src/monitoring.py. TokenTracker.record

```
def record(self, model, input_tokens, output_tokens, operation="chat", latency_ms=0.0):
    """토큰 사용량을 기록합니다."""
    # TODO: record - 호출별 토큰·비용·지연 누적
    # 1. 모델별 단가로 비용 계산 (헬퍼 위임)
    cost_usd = calculate_cost(model, input_tokens, output_tokens, self.COST_PER_1K_TOKEN)

    # 2. 이번 호출의 메타데이터를 딕셔너리 한 건으로 조립
    record = {
        "timestamp": datetime.now(timezone.utc).isoformat(),
        "model": model,
        "operation": operation,
        "input_tokens": input_tokens,
        "output_tokens": output_tokens,
        "total_tokens": input_tokens + output_tokens,
        "cost_usd": cost_usd,
        "latency_ms": round(latency_ms, 2),
    }

    # 3. 기록 리스트에 추가하고 누적 카운터 갱신 + 로그 한 줄
    self._records.append(record)
    self._total_input_tokens += input_tokens
    self._total_output_tokens += output_tokens

    self._logger.info(
        "[TokenTracker] 사용량 기록: model=%s, input=%d, output=%d, cost=$%.6f, latency=%dms",
        model, input_tokens, output_tokens, cost_usd, latency_ms,
    )
```

핵심은 3단계의 **누적 갱신**입니다. `_records` 에 한 건씩 쌓는 건 "최근 호출 내역"을 보여 주기 위함이고, `_total_*` 은 `summary()` 가 매번 리스트를 합산하지 않고 바로 꺼내 쓰도록 미리 합쳐 두는 값입니다.

마지막으로 **조회 메서드 두 개**는 이미 완성돼 있습니다. 우리가 구현할 부분은 없고 헬퍼로 위임만 합니다.

설명 ex07/src/monitoring.py. TokenTracker.summary / recent

```
def summary(self):
    """누적 토큰 사용량 요약을 반환합니다."""
    return token_summary(self)

def recent(self, n=5):
    """최근 n개의 호출 기록을 반환합니다."""
    return token_recent(self, n)
```

`calculate_cost`, `token_summary`, `token_recent` 는 `_monitoring_utils.py` 의 헬퍼입니다. 비용 공식(`input_tokens × input_price / 1000 + output_tokens × output_price / 1000`)과 요약 계산은 헬퍼가 맡고, 우리는 기록을 쌓는 부분만 구현합니다.

7.4 Retry와 ConnectHRAgent — 운영용 래퍼

세 번째 네모에는 슬랙의 "에러가 났어요" 메시지가 떠올랐습니다. 팀장이 마커로 그 위에 작게 적었습니다. **재시도 매뉴얼**.

팀장 : "사서한테 매뉴얼 한 장 쥐여 줘. '한 번 실패하면 3번까지 다시 시도해. 시도 사이에 2초씩 쉬고.'"

오픈이 : "그 정도면 일시적 오류는 대부분 흡수되겠네요."

네트워크가 잠깐 끊기거나 모델이 과부하에 걸리는 일시적 문제는 잠깐 뒤에 다시 시도하면 대부분 풀립니다. 점검 중이던 선반도 잠깐 뒤에 열려 있을 수 있기 때문입니다.

이 재시도 규칙까지 합쳐 챗터 6의 `IntegratedAgent` 에 캐시·모니터링·재시도를 얹은 버전이 **ConnectHRAgent**입니다. 새 기능을 추가하는 것이 아닙니다. 기존 에이전트를 **안정적으로 운영**할 수 있게 감싸는 것이 목표입니다.

기능	역할	파일
응답 캐시	답변 메모장 (1시간 TTL)	<code>cache.py</code>
임베딩 캐시	단어 → 벡터 변환 결과 저장	<code>cache.py</code>
토큰 추적	사서의 업무 일지	<code>monitoring.py</code>
재시도 로직	"3번까지 다시 시도"	<code>agent_config.py</code>

도구도 구조가 바뀝니다. 챗터 6에서 `mcp_tools.py` 하나에 몰아넣었던 도구 4개를 `tools/` 디렉토리 아래 파일별로 분리했습니다(`leave_balance.py`, `sales_sum.py`, `list_employees.py`, `search_documents.py`). 도구가 늘어도 파일 하나씩 추가하면 되는 구조라 관리하기 쉽습니다.



그림 7-6. 챕터 6의 에이전트는 그대로 두고, 바깥을 **운영 래퍼 3종**(캐시·추적·재시도)으로 감쌉니다. 요청은 위에서 들어와 래퍼 3층을 거쳐 코어에 닿고, 응답은 반대 방향으로 나오면서 각 층이 추가 작업(저장·기록)을 수행합니다

실습 3. agent_config.py

ex07/src/agent_config.py 의 `ConnectHRAgent.run()` 메서드 TODO의 `pass` 를 지우고 **5 단계 운영 파이프라인**을 구현합니다. 재시도 루프와 AgentExecutor 빌드는 `_agent_utils.py` 의 `build_agent_executor()` · `run_with_retry()` 헬퍼가 맡고, 우리는 **단계를 조립하는 데만** 집중하면 됩니다.

`run_with_retry` 는 상수 두 개로 동작을 조절합니다. `RETRY_MAX_ATTEMPTS` (기본값 3)가 최대 시도 횟수, `RETRY_DELAY_SECONDS` (기본값 2.0)가 시도 사이 대기 시간입니다. 두 값 모두 `_agent_utils.py` 상단에 선언돼 있고 챕터 6의 에이전트 실행 로직을 이 루프 안으로 옮겨 넣습니다.

참고 ex07/src/_agent_utils.py. 재시도 루프 (완성 코드)

```
# 재시도 상수
RETRY_MAX_ATTEMPTS = 3      # 최대 시도 횟수
RETRY_DELAY_SECONDS = 2.0   # 시도 사이 대기 시간 (초)

def run_with_retry(agent_executor, query, chat_history=None):
    last_error = None
    # 1. 최대 3회까지 시도 루프
    for attempt in range(1, RETRY_MAX_ATTEMPTS + 1):
        try:
            # 2. Agent 실행 - 성공하면 결과를 그대로 반환
            result = agent_executor.invoke({
                "input": query,
                "chat_history": chat_history or [],
            })
            return result
        except Exception as exc:
            # 3. 실패 시 에러를 기억하고 경고 로그 남김
            last_error = exc
            logger.warning(
                "[ConnectHRAgent] 시도 %d/%d 실패: %s",
                attempt, RETRY_MAX_ATTEMPTS, exc,
            )
            # 4. 마지막 시도가 아니면 2초 쉬고 다시 도전
            if attempt < RETRY_MAX_ATTEMPTS:
                time.sleep(RETRY_DELAY_SECONDS)

    # 5. 3회 모두 실패 - 사용자에게 보여줄 안전한 에러 메시지를 반환
    return {"output": f"처리 중 오류가 발생했습니다: {last_error}"}
```

`run_with_retry` 는 최대 3회까지 `agent_executor.invoke` 를 재시도하고 시도 사이에 2초씩 쉽니다. 매 실패에 `logger.warning` 으로 몇 번째 시도가 왜 실패했는지 남기고, 전부 실패하면 에러 메시지를 담은 결과를 반환합니다. 이제 `ConnectHRAgent.run()` 차례입니다.

실습 3 ex07/src/agent_config.py. ConnectHRAgent.run

```
class ConnectHRAgent:
    def run(self, query, chat_history=None, use_cache=True):
        """사용자 질문을 처리하고 답변을 반환합니다."""
        # TODO: run - 캐시 → 라우팅 → 실행(재시도) → 토큰 기록 → 캐시 저장 (5단계)
        start_time = time.time()
        logger.info("[ConnectHRAgent] 질문 수신: %s", query[:80])

        # 1. 캐시 조회 - 같은 질문이면 LLM·DB를 건너뛰고 즉시 반환
        if use_cache:
            cached = response_cache.get(query)
            if cached is not None:
                cached["from_cache"] = True
                logger.info("[ConnectHRAgent] 캐시 응답 반환")
                return cached

        # 2. Router로 경로 결정 - 질문을 RAG · Agent 중 어디로 보낼지 분류
        route = classify_route(query, router=self._router)

        # 3. 경로별 실행 - run_with_retry가 최대 3회까지 자동 재시도
        if route == "rag" and self.rag_chain is not None:
            try:
                # 3-1. RAG 경로: 문서 검색 + 답변 생성 체인 호출
                answer = self.rag_chain.invoke(query)
                result = {
                    "output": answer,
                    "route": route,
                    "intermediate_steps": [],
                    "from_cache": False,
                }
            except Exception as exc:
                # 3-2. RAG 실패 시 Agent로 폴백 (안전장치)
                logger.warning("[ConnectHRAgent] RAG 체인 실행 실패, Agent로 폴백: %s", exc)
                result = run_with_retry(self.agent_executor, query, chat_history)
                result["route"] = "agent_fallback"
                result["from_cache"] = False
        elif self.agent_executor is not None:
            # 3-3. Agent 경로: ReAct 루프 실행 (재시도 포함)
            result = run_with_retry(self.agent_executor, query, chat_history)
            result["route"] = route
            result["from_cache"] = False
        else:
            # 3-4. 에이전트 초기화 실패 - 사용자에게 안내 메시지만 반환
            result = {
                "output": "죄송합니다. 에이전트 서비스를 사용할 수 없습니다.",
                "route": "error",
                "intermediate_steps": [],
                "from_cache": False,
            }
```

```

    }

    # 4. 토큰 사용량 기록 - 모델·입출력 토큰·지연시간을 TokenTracker에 누적
    latency_ms = (time.time() - start_time) * 1000
    provider = os.getenv("LLM_PROVIDER", "ollama").lower()
    if provider == "openai":
        model = os.getenv("OPENAI_MODEL", "gpt-4o-mini")
    else:
        model = os.getenv("OLLAMA_MODEL", "deepseek-r1:8b")
    token_tracker.record(
        model=model,
        input_tokens=len(query.split()) * 2,
        output_tokens=len(result["output"].split()) * 2,
        operation="agent_run",
        latency_ms=latency_ms,
    )

    # 5. 캐시 저장 - 다음에 같은 질문이 오면 1단계에서 바로 꺼내 쓰도록
    if use_cache:
        response_cache.set(query, result)

    logger.info(
        "[ConnectHRAgent] 처리 완료 (경로: %s, 소요: %.0fms)",
        result["route"],
        latency_ms,
    )
    return result

```

1단계와 5단계가 실습 1에서 만든 `response_cache` 와 맞물리고, 4단계가 실습 2의 `token_tracker` 에 기록을 쌓습니다. 챕터 6의 에이전트 실행 로직은 3단계의 `run_with_retry` 안으로 들어갔습니다. 결국 `run()` 메서드 하나가 캐시·라우팅·재시도·모니터링을 순서대로 엮는 허브가 됩니다. 모델 이름은 `LLM_PROVIDER` 값에 따라 `OPENAI_MODEL` 또는 `OLLAMA_MODEL` 환경변수에서 가져오고, 토큰 수는 `단어 수 × 2` (한국어 근사)로 추정합니다. Ollama 응답에 토큰 메타가 없어서 쓰는 임시 계산입니다.

7.5 서버 실행 + 캐시 적중 확인

챕터 6의 `ex06` 서버가 켜져 있다면 `Ctrl+C` 로 먼저 종료합니다. `ex07` 도 같은 8000 포트를 사용하기 때문에, 이전 서버를 내리지 않으면 새 서버가 뜨지 않습니다.

터미널 서버 실행

```
python run.py
```

브라우저에서 `http://localhost:8000/chat` 을 열고, 동료가 처음 했던 질문을 그대로 두 번 던져 보세요.

첫 호출. LLM을 실제로 돌리므로 20초 근처.

```

첫 질문 — ResponseCache MISS

$ python run.py
질문 수신 | 김민준 연차 잔여일수 알려줘
[14:38:38] INFO [ConnectHRAgent] 질문 수신: 김민준 연차 잔여일수 알려줘
[14:38:38] INFO [Router] 쿼리 분류 완료: route=db
[14:38:45] INFO HTTP Request: POST http://localhost:11434/api/chat "HTTP/1.1 200 OK"
[14:38:45] INFO 조회 대상: 김민준
[14:38:45] INFO 결과: {'employee_name': '김민준', 'dept': '영업부', 'total_leaves': 15.0, 'used_leaves': 7.0,
    'remaining_leaves': 8.0}
[14:38:46] INFO HTTP Request: POST http://localhost:11434/api/chat "HTTP/1.1 200 OK"
[14:38:46] INFO [TokenTracker] 사용량 기록: model=llama3.1:8b, input=8, output=8, cost=$0.000000, latency=8019ms
TokenTracker 기록
모델 llama3.1:8b
입력 토큰 8
출력 토큰 8
비용 (USD) $0.000000
지연 시간 8019 ms
[14:38:46] INFO [ResponseCache] 저장: key=5e1dc59daa6e... (만료: 3600초 후)
[14:38:46] INFO [ConnectHRAgent] 처리 완료 (경로: db, 소요: 8019ms)
처리 완료 | 경로=db · 소요=8019ms
INFO: 127.0.0.1:64430 - "POST /api/chat HTTP/1.1" 200 OK
    
```

그림 7-7. 첫 질문 로그. 입력, 출력 토큰과 소요 시간이 TokenTracker에 기록됩니다

두 번째 호출. ResponseCache HIT.

```

두 번째 질문 — ResponseCache HIT

$ python run.py
질문 수신 | 김민준 연차 잔여일수 알려줘
[14:38:46] INFO [ConnectHRAgent] 질문 수신: 김민준 연차 잔여일수 알려줘
[14:38:46] INFO [ResponseCache] 적중: key=5e1dc59daa6e... (잔여 TTL: 3600초)
ResponseCache HIT | LLM·DB 호출 없이 즉시 반환
[14:38:46] INFO [ConnectHRAgent] 캐시 응답 반환
INFO: 127.0.0.1:64447 - "POST /api/chat HTTP/1.1" 200 OK
    
```

그림 7-8. 같은 질문에 캐시 HIT. 0.1초 이내 응답 반환

첫 호출과 캐시 적중을 나란히 비교하면 비용 차이가 한눈에 보입니다.

첫 질문		캐시 적중
LLM 호출	2회 (분류 + 답변)	0회
DB 조회	1회	0회
소요 시간	약 16초	즉시 반환
로그	AgentExecutor 체인 전체 출력	[ResponseCache] 적중 한 줄

[잔여 TTL: 3386초](#) . 메모장에 적힌 지 약 3분이 지났다는 뜻입니다($3600 - 3386 = 214$ 초). TTL이 0이 되면 메모가 만료되고, 다음에 같은 질문이 들어오면 다시 서가에서 찾아옵니다.

[/stats](#) 엔드포인트를 열면 호출마다 쌓인 누적 통계가 나옵니다. 실제 운영 환경이라면 이 화면이 하루, 일주일 단위로 의미 있어집니다.




그림 7-9. 누적 호출 수, 토큰, 비용, 캐시 적중률 대시보드

같은 질문을 다시 던지자 로딩 스피너가 한 번도 뜨지 않고 답이 바로 나왔습니다. 20초가 0.1초로 줄었습니다. 오픈이는 의자 등받이에 기대며 모니터를 바라봤습니다.

이제 동료한테 한 소리 덜 들겠네.

슬랙에 스크린샷을 하나 올렸습니다. 같은 질문을 두 번 연달아 던진 타임스탬프가 0.1초 간격으로 찍혀 있었습니다.

동료 : "캐시 적중률 72%네요. 10번 중 7번은 LLM을 안 돌린 거잖아요."

오픈이 : "그리고 실패한 것도 재시도로 자동 복구됩니다. 이제 '고장났다'는 메시지가 줄어들 거예요."

7.6 더 알아보기

TTL을 얼마로 설정해야 할까요? 사내 문서가 자주 갱신되면 짧게(30분), 변동이 거의 없으면 길게(24시간) 잡습니다. 기본값 1시간은 대부분의 사내 환경에 무난합니다. `.env` 의 `CACHE_TTL=3600` 값을 프로젝트마다 조정합니다.

서버를 재시작하면 ResponseCache가 사라지지 않나요? 맞습니다. 인메모리 딕셔너리라 프로세스 종료와 함께 날아갑니다. 운영 환경에서는 **Redis** 같은 외부 캐시로 교체하는 것이 일반적입니다.

`get()` · `set()` 메서드 안의 `self._store` 조작을 Redis 클라이언트 호출로 바꾸면 동일 인터페이스를 유지하면서 영속성을 얻을 수 있습니다.

토큰 수가 추정값인 이유는? Ollama는 응답 메타데이터에 토큰 사용량을 포함하지 않습니다. 그래서 이 책에서는 `단어 수 × 2` 를 한국어 기준 대략적 추정치로 씁니다. 정확한 과금이 필요한 OpenAI API는 응답 객체의 `usage.prompt_tokens` / `usage.completion_tokens` 를 읽어 실제 값으로 대체하면 됩니다.

7.7 전체 구성도에서 챕터 7의 자리

전체 구성도. 짙은 박스가 챕터 7 범위

사내 직원 · 관리자

챕터 2

대시보드

FastAPI

REST API · 관리자 웹

챕터 6 + 챕터 7

오케스트레이션 + 운영

운영 래퍼

Query Router

규칙·스키마·LLM

+ 캐시 · 재시도

ConnectHRAgent

ReAct + TokenTracker

+ 임베딩 캐시

MCP Tools

DB 조회 · 문서 검색

챕터 5

검색 (실시간)

LCEL Chain

검색기 → 프롬프트 → LLM

챕터 4

파싱·벡터화 (오프라인)

챕터 3 문서 규칙

PDF·Word·Excel·HWP

Doc Pipeline

파싱·청킹·임베딩

ChromaDB

벡터 저장소

챕터 2

데이터

PostgreSQL

직원·연차·매출

Ollama LLM (외부)

챕터 7은 새 박스를 엮지 않고 **챕터 6 오케스트레이션 세 박스를 운영 래퍼로 감싼 챕터**입니다. 같은 에이전트지만 이제는 캐시, 토큰 추적, 재시도가 붙어 실제 배포에 견딥니다. 챕터 8부터는 검색 품질 튜닝(Hybrid Search, Reranker) 영역으로 넘어갑니다.

종료합니다

`Ctrl + C` 로 서버를 종료합니다. Docker 컨테이너는 챕터 8에서도 같은 PostgreSQL·ChromaDB를 쓰므로 그대로 두세요.

용어 정리

본문 속 표현	진짜 용어	정식 정의
"답변 메모장"	ResponseCache	TTL 기반 인메모리 응답 캐시. SHA-256 해시 키로 질문을 식별
"임베딩 메모장"	EmbeddingCache	파일 기반 임베딩 벡터 캐시. pickle로 저장·유지
"업무 일지"	TokenTracker	LLM 호출별 입출력 토큰·비용·응답시간을 누적 집계
"3번까지 다시 시도"	Retry 로직	LLM 호출 실패 시 최대 N회까지 재시도. 간격 포함
"운영 래퍼"	ConnectHRAgent	챕터 6의 IntegratedAgent에 캐시·모니터링·재시도를 통합한 운영용 에이전트

이것만은 기억하자

- **같은 질문은 같은 답이 빠르게.** ResponseCache(TTL)로 20초 → 0.1초. 하지만 TTL 만료, 규정 개정 시엔 무효화가 필요하다는 점을 잊지 마세요.
- **측정이 개선의 시작입니다.** TokenTracker로 토큰, 비용, 응답시간을 쌓아 두면 "느린 질문", "비싼 질문"이 눈에 보입니다. 실무에서는 Langfuse, LangSmith 같은 도구를 얹어 대시보드화합니다.
- **실패는 기본입니다.** 네트워크 오류, 파싱 실패가 드물지 않습니다. Retry 루프(3회, 2초 간격)만 있어도 체감 장애 빈도가 크게 줄어듭니다. 챕터 8부터는 이 위에서 **검색 품질 자체**를 튜닝합니다.